

文章编号: 1007-5429(2021)04-0011-08

DOI: 10.19495/j.cnki.1007-5429.2021.04.002

顾客完全时空柔性的往返式共享汽车调度研究

江镭行, 苏强*, 孙淑慧
(同济大学经济与管理学院, 上海 201800)

摘要: 人均汽车保有量的快速增加给城市交通带来了极大的压力, 共享汽车服务模式可以有效解决这个问题。针对往返式共享汽车调度, 有学者引入顾客时空柔性以实现供需的一致性, 但其模型只考虑了顾客延迟服务的情况。基于此, 提出了顾客提前/延迟服务的完全时空柔性模型, 设计了自适应大规模邻域搜索算法进行求解, 并应用温哥华的仿真数据集进行数值验证。结果表明, 完全时空柔性模型可提升运营商的收益和顾客服务率。通过参数灵敏度分析, 柔性订单比例越大, 系统的收益和顾客满意度提升越大。

关键词: 往返式共享汽车; 完全时空柔性; ALNS 算法; 仿真数据集

中图分类号: C931

文献标识码: A

Research on Customer's Complete Space-Time Flexible Round-Trip Shared Vehicle Scheduling

JIANG Ronghang, SU Qiang*, SUN Shuhui
(School of Economics and Management, Tongji University, Shanghai 201800, China)

Abstract: The rapid increase of per capita car ownership brings great pressure to urban traffic, and the shared car service can effectively solve this problem. For round-trip shared car scheduling, some scholars introduced customer spatio-temporal flexibility to achieve the consistency of supply and demand, but their model only considered the case of customer delayed service. Based on this, a complete spatio-temporal flexibility model of customer advance / delay service was proposed, and an adaptive large-scale neighborhood search algorithm (ALNS) was designed to solve the model, and the simulation data set of Vancouver was used for numerical experiment. The results show that the complete spatio-temporal flexibility model can improve the revenue and customer service rate of operators. Through parameter sensitivity analysis, the larger the proportion of flexible order, the higher the system's revenue and customer satisfaction.

Key words: round-trip shared car; complete space-time flexibility; ALNS; simulation data set

1 引言

随着中国经济的发展和人民生活水平的提

高, 中国的私人汽车保有量快速增加, 给城市交通、环境污染等方面带来了极大的压力。在这种困境下, 共享汽车应运而生。共享汽车使消费者

收稿日期: 2020-01-06

基金项目: 国家自然科学基金重点项目(71432007); 国家自然科学基金面上项目(71972146)

作者简介: 江镭行(1997-), 浙江杭州人, 硕士研究生, 主要研究方向为物流与供应链、共享汽车和智能决策。E-mail: jiangrh@tongji.edu.cn。

*通信作者: 苏强, 教授, 博士, E-mail: suq@tongji.edu.cn。

无需购买汽车即可享受出行服务,在满足顾客的个性化出行需求的同时提高车辆使用率、减少交通拥堵、节省土地空间。在这种形式下,共享汽车调度和顾客体验的优化问题成为学界和业界的关注焦点。

本文重点关注分时租赁型共享汽车的优化调度。共享汽车可分为单程式(one-way)和往返式(round-trip)。前者允许异地还车,可满足顾客的个性化需求,但也带来了车辆数不平衡问题。该问题通常采用人工部署方式解决,但大大增加了运营成本。后者固定了取车和还车的站点,不存在车辆数不平衡的问题,可节省大量成本。另外,往返式共享汽车作为较早的共享汽车服务模式,在世界范围内应用广泛,故本文选择往返式共享汽车进行研究。

往返式共享汽车调度的最新研究以 Stroehle 等^[1]的工作为典型,引入了顾客时空柔性概念,其中:时间柔性指顾客开始服务的时间可变,服务的时长不变;空间柔性指顾客预订的车站可变。他们利用顾客的时空柔性对车队运营进行优化,建立了混合整数规划数学模型,用德国一个中型城市数据进行验证,发现时空柔性最大可节约 20% 的车队数目。但研究发现,Stroehle 的顾客时间柔性只考虑了顾客延迟服务的情形,未充分考虑顾客提前/延迟服务两种情形,是一种受限制的时空柔性。本文对其工作进行扩展,构建了考虑顾客提前/延迟服务的完全时空柔性模型,对共享汽车的运营进行优化。

2 文献综述

目前共享汽车的相关研究主要集中于需求的预测、单程式共享汽车调度以及往返式共享汽车的调度。

首先,顾客需求的预测分为宏观需求预测和微观旅行预测。宏观需求预测方面:Steininger 等^[2]以用户为中心,通过调查和控制试验,对用户的特征和行为进行了描述;Catalano 等^[3]通过偏好实验和运输需求模型,展现了共享汽车较其他运输方式的竞争优势;Shaheen 等^[4]进行了个人专家访谈,调查了个人汽车共享的发展,指出了共享汽车未来发展

的方向;Schmöller 和 Bogenberger^[5]使用了数据拟合方法分析共享系统的预订数据,结果表明“天气”似乎对共享汽车需求没有影响,而“城市的年龄结构”有很大影响;Alencar 等^[6]收集了温哥华地区往返式、单向式和自由流动共享汽车系统的数据,揭示了它们的用户习惯和服务模式。微观汽车共享需求预测方面:Barth 和 Todd^[7]提出了“车辆行程比”、“车辆站点比”、“空车时间”以及“满车位时间”描述共享汽车需求;Xu 和 Lim^[8]提出了一种基于进化神经网络(ENN)的预测模型以预测净流量;Ke 等^[9]针对共享汽车需求的空间依存性、时间依存性和外生依存性,提出了融合卷积短期记忆网络(FCL-Net)的方法,并用滴滴出行的真实数据验证该方法的有效性;Heilig 等^[10]利用社会人口统计数据数据进行建模,对共享汽车一周的需求进行模拟;Wang 等^[11]收集了上海地区共享汽车数据,研究了影响共享汽车服务需求的相关指标,构建了单向电动共享汽车系统的需求预测模型。

其次,大多数学者关注单程式共享汽车调度,而站点选址问题和重部署问题是单程共享汽车调度问题的研究重点。众多研究采用数学建模的方法:Correia 和 Antunes^[12]提出了一种混合整数规划模型,用于确定单向汽车共享系统最优的站点位置;Correia 等^[13]扩展了该模型,以探索空间用户灵活性和车辆库存信息的影响;Smith 等^[14]研究了共享汽车和出租车服务相结合的重部署问题,建立线性规划模型优化驾驶员路径以及驾驶员数量和车辆数;He 等^[15]研究了共享汽车运营商服务区的规划问题,建立了分布式的鲁棒优化框架以克服数据的缺乏。数学模型方法对计算机性能要求较高,一些研究采用仿真的方法:Kek 等^[16]开发了一种仿真模型,以探究库存平衡技术在提高服务水平方向的潜力;Alfian 等^[17]开发了一种基于模糊分类的仿真工具,设计了 36 种服务类型组合,使用仿真算法评估模型的性能;Illgen 和 Höck^[18]使用了仿真的方法将电动汽车与燃油汽车进行比较,发现市场的关键成功因素在于电力和燃油的价格。还有学者专注于优化运行效率:Lin 等^[19]提出了一个多智能体强化学习框架,用于大规模在线拼车平台的车队管理决策;Zhang 等^[20]针对电动共享汽车蓄电池容量不足

的问题,建立了改进的时空网络流模型,进行车辆的分配以及行车路径的决策,提高了车辆利用率和用户满意度。

最后,关于往返式共享汽车的研究较少,学者的关注点集中于减少车队规模和提高车辆使用率: Balac 和 Ciari^[21]试图通过改善车站的车辆租赁方式以提高往返式共享汽车的车辆利用率; Jorge 等^[22]在往返式共享汽车中加入单程式服务,开发了一个整数规划模型,结果显示该方案可增加收入,减少共享汽车站点。往返式共享汽车的最新研究是 Stroehle 等引入顾客的时间和空间柔性的概念来优化车队运营,开发了一个混合整数规划,发掘了顾客柔性在往返式共享汽车问题中的优化潜力。Stroehle 等人引入时空柔性概念,对往返式共享汽车领域的研究有极大的推进,但其工作仍存在不足。为了弥补现有工作的不足,本文的创新如下:

(1) 模型构建上, Stroehle 等人时间柔性只考虑了顾客预定延迟的情况,未考虑顾客预定提前的情况,是一种不完全的时空柔性模型。本文考虑了顾客提前/延迟服务两种情形,建立了完全时空柔性模型。

(2) 求解方法上, Stroehle 等人使用 gurobi 求解,虽然可以得到质量较高的解,但在大规模算例情况下耗时较长。本文设计了 ALNS 算法进行求解,在保持一定求解质量的情况下减少时间开销。

(3) 算例验证上, Stroehle 等人基于历史数据,仅包含运营中被满足的需求,而未被满足的需求并未被记录。本文根据温哥华顾客需求特征,随机生成仿真数据集以模仿真实的顾客需求。

3 模型

本节的数学模型是具有时间窗的多机调度问题,对客户提前/延迟服务罚款,固定车队规模 and 客户服务决策。阅读大量文献发现,关于此问题的研究很少。

3.1 问题定义

定义车站集合 S , 车辆集合 V 和客户集合 R 。每个车站对应于一列车辆和一定范围的客户,需选择车辆向合适的客户提供服务。模型的主要参数定义如表1所示。

表1 模型参数表

符号	含义
S	车站集合
V	车辆集合
R	订单集合, $R_1, R_2, R_3 \in R$, 分别表示不同时间成本的订单
γ_r	顾客 r 对应的成本系数
σ_v	车辆到车站的映射
σ_r	顾客订单到车站的映射
t_r^b	顾客 r 的订单要求的使用车辆的起始时间
t_r^e	顾客 r 的订单要求的使用车辆的结束时间
α_1	单位车辆的运营成本
α_2	单位车辆单位时间的运营收益
α_3	单位时间柔性成本
α_4	单位空间柔性成本
d_{rv}	空间成本矩阵, 由顾客 r 与 v 车辆的距离决定
T_{rv}^a	订单 r 在 v 车辆的提前时间
T_{rv}^d	订单 r 在 v 车辆的延迟时间
θ_r^a	订单 r 可提供的提前时间柔性
θ_r^b	订单 r 可提供的延迟时间柔性

假设在每天运营之前, 客户集合 R 根据映射 σ_r 向与其关联的站点 s 提交订单, 而运营商根据 σ_v 安排站点中的车辆 v 满足客户的需求。

考虑到空间柔性, 若相关站点无法为其提供服务, 那运营商可选择另一站点的车辆为该顾客提供服务。当然, 这需要运营商支付额外的空间柔性成本, 距离成本矩阵 d_{rv} 得到。

考虑到时间柔性, 即使汽车上的原始客户订单发生冲突, 也可以通过保留或延迟客户订单的服务来防止服务发生冲突。假设运营商需要顾客提供时间柔性 T , 时间柔性成本按 $T \times \gamma_r$ 计算。

3.2 数学模型

完全时空柔性的返共享汽车的数学模型如下所示。

目标函数:

$$\text{Max } \alpha_2 \sum_{r \in R} \sum_{v \in V} x_{rv} (t_r^e - t_r^b) - \alpha_1 \sum_{v \in V} u_v - \alpha_3 \left(\sum_{r \in R} \sum_{v \in V} \gamma_r (T_{rv}^a + T_{rv}^d) \right) - \alpha_4 \sum_{r \in R} \sum_{v \in V} x_{rv} d_{rv} \quad (1)$$

约束条件:

$$x_{rv} \leq u_v, \forall r \in R, \forall v \in V \quad (2)$$

$$\sum_{v \in V} x_{rv} \leq 1, \forall r \in R \quad (3)$$

$$x_{rv} \leq D_{rv}, \forall r \in R, \forall v \in V \quad (4)$$

$$t_{r_1}^e - T_{r_1 v}^a + T_{r_1 v}^d \leq t_{r_2}^b - T_{r_2 v}^a + T_{r_2 v}^d, \forall r \in R, \forall v \in V, \\ t_{r_1}^e \leq t_{r_2}^e \quad (5)$$

$$0 \leq T_{rv}^a \leq \min(\theta_r^a, x_{rv} M), \forall r \in R, \forall v \in V \quad (6)$$

$$0 \leq T_{rv}^d \leq \min(\theta_r^b, x_{rv} M), \forall r \in R, \forall v \in V \quad (7)$$

$$x_{rv} = \begin{cases} 1, & \text{if 订单 } r \text{ 分配给车辆 } v \\ 0, & \text{else} \end{cases} \quad (8)$$

$$u_v = \begin{cases} 1, & \text{if 车辆 } v \text{ 被使用} \\ 0, & \text{else} \end{cases} \quad (9)$$

目标式(1)表示运营总收益最大化的目标,其中包含四个部分:第一部分表示订单集合 R 被完成时的总收益;第二部分表示车辆 u_v 投入运营的总成本;第三部分表示订单 R 中需要提供时间柔性订单 r 的时间柔性总成本;第四部分表示订单 R 中需要提供空间柔性订单 r 的空间柔性总成本。约束式(2)表示只有投入运营的车辆 v 才能为订单 r 服务。约束式(3)表示每个订单只能同时由一辆车或零辆车服务,后者表示该订单被拒绝。约束式(4)是空间约束,指只能由空间可达的车辆 v 为订单 r 服务, $D_{rv} = 1$ 表示车辆 v 对于订单 r 可达, $D_{rv} = 0$ 表示不可达。约束式(5)是时间约束,表示在同一车辆 v 上的先服务订单 r_1 的结束时间不晚于之后订单 r_2 的开始时间。约束式(6)和式(7)分别指定了订单时间提前柔性和延迟柔性的上下界。式(8)为订单 r 是否分配给车辆 v 的决策变量,若订单 r 分配给车辆 v 则 $x_{rv} = 1$, 否则 $x_{rv} = 0$ 。式(9)为车辆 v 是否投入使用的决策变量,若车辆 v 投入使用则 $u_v = 1$, 否则 $u_v = 0$ 。

4 自适应大规模邻域搜索算法(ALNS)

CPLEX 在合理的计算时间内只能求解小规模算例。因此,设计了一个 ALNS 算法进行求解,查阅文献发现,这是往返式共享汽车调度的第一个 ALNS 算法。

4.1 ALNS 算法概述

Shaw^[23]首先提出了自适应的大规模邻域搜索算法(ALNS),算法的基本思想是通过破坏算子和修复算子来优化每次迭代中的当前解。ALNS 算法框架图如图 1 所示。

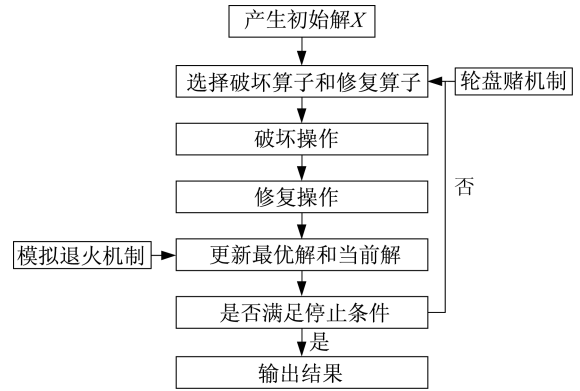


图 1 ALNS 算法框架图

ALNS 算法通过轮盘赌机制选择合适的算子^[24]。选择算子的概率都会受到其在过去迭代中的性能的动态影响。若算子改进当前解,则概率增加;否则,概率可能会降低。若新解改进了当前解,则接受该新的解;否则,根据模拟退火机制按概率接受。

4.2 初始解生成及解评估

每辆车生成按时间顺序排列的初始客户任务,初始解的构造过程如下:

第 1 步:使用 $1, 2, \dots, n$ 按服务起始时间顺序标注所有顾客,服务起始时间越早的顾客拥有越小的编号。

第 2 步:将每个客户随机分配到他们选择的站点上的车辆。

第 3 步:按时间顺序安排每辆车的客户订单。

接着是解评估操作,根据每辆车被分配的顾客来确定服务的客户订单,利用 Cplex 进行服务决策以及时间柔性决策。如将订单 r_1, r_2, r_3 分配给车辆 v : 服务决策 $[1 \ 1 \ 0]$ 表示该车辆服务 r_1, r_2 订单,不服务 r_3 订单;时间柔性决策包括提前服务决策 $[t_1 \ 0 \ 0]$ 和延迟服务决策 $[0 \ t_2 \ 0]$ 表示 r_1 订单需提前 t_1 时间服务, r_2 需延迟 t_2 时间服务。

4.3 破坏/修复算子的选择

ALNS 算法通过轮盘赌机制选择破坏算子和修复算子。首先,以相同的概率选择破坏算子和修复算子。算法执行过程中,根据 $p_i^{t+1} = p_i^t(1-r) + r\beta_i^t/\alpha_i^t$ 更新每个算子的概率。其中: p_i^t 是在第 t 次迭代中选择算子 i 的概率; $r \in [0, 1]$ 是预定义的系数; α_i^t 是在过去的 t 次迭代中选择算子 i 的次数; β_i^t 是算子 i 在第 t 次迭代中的得分。

算子的得分用于衡量每次迭代中的性能^[25]。若找到新的最优解,则算子的分数增加 Q_1 ; 若新解

比当前解更好,算子的分数增加 Q_2 ;若新解比当前解差,但仍然被接受为新的当前解,算子的得分增加 Q_3 。

4.4 破坏算子

ALNS算法包含两种破坏算子:第一种破坏算子旨在删除 $k=n\rho$ 个订单(破坏因子 $\rho \in [0,1]$, n 为订单总数),共3个算子;第二种破坏算子旨在删除车辆上的所有订单,共2个算子。

(1) 随机破坏算子:一次随机选择 k 个客户,将其从当前车辆中去除,并将其置于删除列表 LR 中,该算子有助于增加解的多样性。

(2) shaw 破坏算子:旨在消除具有相同请求特征的一系列客户需求,防止订单在修复阶段被插回其原始位置。

(3) 收益破坏算子:计算每个客户的当前收益,然后删去最低的 k 个。

(4) 随机路径破坏算子:随机选择车辆,破坏其所有订单。

(5) 最长路径破坏算子:选择顾客数最多的车辆,破坏其所有订单。

4.5 修复算子

修复算子以不同的目的将 LR 中的订单插回至待修复解中。

(1) 贪婪修复算子:选择可达插入收益最低的车辆,将顾客插入。

(2) 可行性修复算子:选择可达的服务顾客最少的车辆(不为空),将顾客插入,增加车辆的利用率。

(3) 随机修复算子:将顾客随机插入至可行车辆中,增加解的多样性,避免过早的收敛。

4.6 接受和停止准则

ALNS算法采用模拟退火作为外部局部搜索框架,框架如图2所示。 s_{best} 表示算法的最优解, s_{curr} 是当前解, s' 是指在迭代中的临时解,可以将其丢弃或接受作为下次迭代的当前解。可行解 X 的目标函数值由 $f(X)$ 表示。若 $f(s') < f(s_{curr})$, 则接受 s' , 否则 s' 将以 $e^{-\frac{f(s') - f(s_{curr})}{T}}$ 的概率被接受。其中 T 表示模拟退火温度参数,初始设置为 $T = f(s_{init}) \times P_{init}$ 。 $f(s_{init})$ 是初始解的目标函数值, P_{init} 则是一个常数,模拟退火的冷却速率为 $h \in (0,1)$, 每次迭代后取 $T = hT$ 。

ALNS 算法框架

```

1:生成初始可行解  $s_{init}$ ;最大迭代次数  $itermax$ 
2:令当前解  $s_{curr}=s_{init}$ ;最优解  $s_{best}=s_{init}$ ; 初始迭代次数  $iter=1$ 
3:while  $iter \leq itermax$ 
4:   轮盘赌机制: 选择破坏算子  $h_{rem}$  和修复算子  $h_{ins}$ 
5:   破坏:应用破坏算子  $h_{rem}$  从  $s_{curr}$  中移除  $\rho$  个顾客, 得到  $s_{rem}$ 
6:   修复:应用修复算子  $h_{ins}$  将被移除的顾客插入至  $s_{rem}$  得到一个新解  $s'$ 
7:   if  $f(s') > f(s_{best})$  then
8:      $s_{best}=s'$ 
9:      $s_{curr}=s'$ 
10:  elseif  $f(s') > f(s_{curr})$ 
11:     $s_{curr}=s'$ 
12:  elseif  $accept(s_{curr}, s')$  then
13:     $s_{curr}=s'$ 
14:  end if
15:  更新轮盘赌参数;  $iter=iter+1$ 
16:end
17:返回最优解  $s_{best}$ 

```

图2 ALNS算法伪代码图

5 数值试验

5.1 案例概况

5.1.1 顾客到达

对温哥华的 modo 公司 5 个月的数据进行统计发现温哥华平均一个车站拥有 1.29 辆汽车,选择拥有 2 辆车的某站点进行分析,将其根据到达率将一天分为 6 个时段,具体如表 2 所示。

表2 顾客到达率表

时段	到达率
0—6	0.044 1
7—8	0.161 8
9—12	0.933 8
13—16	0.573 5
17—20	0.595 6
21—24	0.154 4

数据显示 9 点至 12 点期间顾客到达最为频繁,暗示了顾客的时间柔性价值,将空闲时段分配给频繁时段的顾客,可提高顾客服务率以及整体收益。

5.1.2 服务时间

对温哥华的 modo 公司 5 个月的数据进行统计,获得顾客服务时间频率如图 3 所示。




图3 顾客服务时间比例图

数据显示大部分顾客的服务时间集中于0—5小时,利用matlab进行KS检验得该数据在1%显著水平下服从 $u=4.838$ 小时的负指数分布,拟合得到分布参数如表3所示。

表3 顾客服务时间指数分布拟合表

分布	对数似然估计	均值	标准差	方差
指数分布	-443.175	4.838	0.369	23.411

5.1.3 站点位置

站点位置数据来自温哥华市modo公司。假设每个站点存放2辆车,以5.1.1的参数生成顾客需求,以5.1.2的参数生成顾客服务时间,具体的站点位置如图4所示。

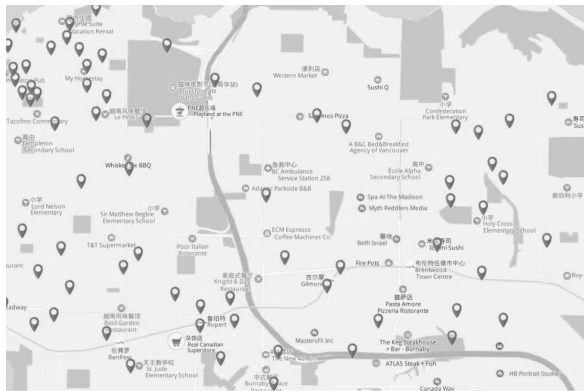


图4 站点位置图

5.2 计算机参数及算法参数

采用matlab 2018b编写程序,计算机为64位操作系统,处理器为Intel®、Core(TM) I5-8300H、CPU@2.30 GHz,内存8 GB。参数设置为与最优解平均偏差最小的值,具体参数见表4。

第一组参数为轮盘赌轮机定义选择过程。类似于Demir^[26],设置参数 $Q_3 \geq Q_1 \geq Q_2$,有助于搜索的多样化。

表4 算法参数表

类别	名称	参数
1	最大迭代次数MAXGEN	1 000
	破坏算子取点系数 ρ	0.1
	计算选择算子概率的预定义系数 r	0.5
	新解为最优解评分 Q_1	3
	新解优于当前解评分 Q_2	1
	新解模拟退火机制作为当前解评分 Q_3	5
2	接受机制的模拟退火冷却速率 h	0.9
	初始化温度系数 P_{init}	100

第二组参数用于校准模拟退火机制框架,定义了算法的初始温度和冷却速率。图5是30站点数的算法表现,该图显示1 000迭代次数时算法收敛。




图5 算法迭代次数图

5.3 结果分析

5.3.1 服务模式比较

按0.5的比例生成柔性订单和无柔性订单,以1:1:1的比例将订单分为低时间柔性成本订单、标准订单以及高时间柔性成本顾客,在不同规模的站点数情况下进行了数值试验,结果如表5所示。

相较于无柔性模型,受限制的时空柔性模型平均多获得9.57%的收益,顾客的服务率提升13.13%,而完全时空柔性模型平均多获得11.32%的收益,服务率提升17.49%。这说明车辆数一定,完全时空柔性模型较受限制的时空柔性模型,可小幅度提高收益,较大幅度提高顾客服务率。

5.3.2 算法比较

Stroehle的研究采用了gurobi求解,采用ALNS算法进行了求解。为验证ALNS算法自适应选择算子机制的有效性,加入大规模邻域搜索算法(LNS)比

较。cplex 计算时间设置为 1 000 s,LNS 算法仅使用 收益破坏算子和贪婪修复算子,结果如表 6 所示。

表 5 顾客收益、服务率对比表

站点数	订单数	完全柔性			受限制柔性			无柔性		
		目标函数	顾客数	比例/%	目标函数	顾客数	比例/%	目标函数	顾客数	比例/%
10	49	3 015.65	46	93.88	3 004.16	44	89.80	2 582.83	36	73.47
20	121	5 939.01	119	98.34	5 725.94	108	89.26	5 447.66	96	79.34
30	154	9 052.37	146	94.81	8 922.78	142	92.21	8 278.36	128	83.12
40	227	11 376.86	214	94.27	11 265.03	210	92.51	10 394.56	181	79.74
50	297	15 621.73	281	94.61	15 370.04	267	89.90	13 786.84	219	73.74
60	331	16 546.48	307	92.75	16 295.65	294	88.82	15 037.45	246	74.32
均值	—	—	—	94.78	—	—	90.41	—	—	77.29

表 6 算法比较表

算例规模	Cplex			ALNS		LNS	
	目标函数	计算时间	Gap	目标函数	计算时间	目标函数	计算时间
站点数=10,顾客数=49	3 029.35	66	—	3 025.77	521	2 921.15	372
站点数=20,顾客数=121	5 944.46	2 253	2.18%	5 939.01	874	5 794.12	779
站点数=30,顾客数=146	9 288.22	6 164	1.57%	9 052.37	982	9 052.37	937
站点数=40,顾客数=227	—	—	—	11 361.78	1 526	11 344.92	1 496

求解时间以秒为单位,站点数为 10 的小规模算例 cplex 表现良好,求解时间和求解质量均优于 ALNS 算法。但从站点数为 20 开始,与 cplex 方法相比,ALNS 算法求解质量平均降低 0.92%,但求解时间平均减少 72.6%。站点数为 40 时 cplex 因内存不足已无法求解。与 LNS 算法相比,ALNS 算法求

解质量平均高 1.56%,时间开销平均高 14.8%。综上所述,选择 ALNS 算法求解是合理的。

5.3.3 参数分析

取站点数为 10,顾客时间柔性成本比例不变时,改变柔性订单的比例进行试验(因规模较小,均由 cplex 求解),结果如表 7 所示。

表 7 柔性订单比例对比表

柔性比例	完全柔性			受限制柔性			无柔性		
	目标函数	顾客数	比例/%	目标函数	顾客数	比例/%	目标函数	顾客数	比例/%
0.1	2 991.34	43	87.76	2 991.34	43	87.76	2 979.72	43	87.76
0.3	3 025.18	43	87.76	3 025.18	43	87.76	2 979.72	43	87.76
0.5	3 029.35	45	91.84	3 027.70	45	91.84	2 979.72	43	87.76
0.7	3 043.27	45	91.84	3 035.97	45	91.84	2 979.72	43	87.76
0.9	3 043.28	45	91.84	3 043.28	45	91.84	2 979.72	43	87.76

柔性订单比例越高,顾客时空柔性可获得更大的收益和顾客服务率,当柔性比例从 0.1 提升至 0.9 时,完全时空柔性模式的收益提高 1.74%,顾客服务率提高 4.08%。而订单柔性比例相同时,完全时空柔性往往比受限制时空柔性获得更多收益和顾客服务率。这说明运营商通过宣传、物质激励的方式促进柔性订单比例的提高将有助于其利用顾客时空柔性优化调度。

6 结论与展望

建立了完全时空柔性的往返式共享汽车调度

模型,将顾客柔性从只考虑顾客延迟服务的服务模式扩展至顾客提前与延迟服务共同作用的模式,主要得到以下成果:

(1) 与无时空柔性模型相比,即使是较为保守的 50%,柔性比例下完全时空柔性的收益平均提高 11.58%,顾客服务率平均提高 17.30%。

(2) 完全时空柔性策略的实施,将顾客只能延迟服务的模式扩展至提前/延迟服务两种模式,增加了模型的优化空间。与受限制时空柔性模式相比,完全的时空柔性模式的收益平均提高 1.75%,顾客服务率平均提高 4.36%。

(3) 柔性订单比例越大,调度优化的收益越大。当柔性比例从 0.1 提升至 0.9 时,完全时空柔性模式收益提高 1.74%,顾客服务率提高 4.08%。

结论说明了顾客完全时空柔性的有效性,为当前共享汽车行业的运营优化带来一定的启发。但不足之处在于调度模型的目标是收益最大化,模型更青睐用车时间更长的单个顾客,因用时长顾客会带来更大的收益。在未来的研究中可以考虑收益和服务率的双目标优化,在服务率和总收益的抉择中维持平衡。

参考文献:

- [1] Stroehle P, Flath C, Gärtner J. Leveraging customer flexibility for car-sharing fleet optimization [J]. *Transportation Science*, 2019, 53(1): 42-61
- [2] Steining K, Vogl C, Zettl R. Car-sharing organizations: The size of the market segment and revealed change in mobility behavior [J]. *Transport Policy*, 1996, 3(4): 177-185.
- [3] Catalano M, Casto B L, Migliore M. Car sharing demand estimation and urban transport demand modelling using stated preference techniques [J]. *European Transport/Trasporti Europei*, 2008, 40: 33-50
- [4] Shaheen S A, Mallery M A, Kingsley K J. Personal vehicle sharing services in North America [J]. *Research in Transportation Business & Management*, 2012, 3: 71-81.
- [5] Schmöller S, Bogenberger K. Analyzing external factors on the spatial and temporal demand of car sharing systems [J]. *Procedia-Social and Behavioral Sciences*, 2014, 111: 8-17.
- [6] Alencar V A, Rooke F, Cocca M, et al. Characterizing client usage patterns and service demand for car-sharing systems [J]. *Information Systems*, 2019: 101448.
- [7] Barth M, Todd M. Simulation model performance analysis of a multiple station shared vehicle system [J]. *Transportation Research Part C: Emerging Technologies*, 1999, 7(4): 237-259.
- [8] Xu J, Lim J S. A new Evolutionary Neural Network for forecasting net flow of a car sharing system [C]//*Proceedings of the 2007 IEEE Congress on Evolutionary Computation*. New York: IEEE, 2007: 1670-1676.
- [9] Ke J, Zheng H, Yang H, et al. Short-term forecasting of passenger demand under on-demand ride services: a spatio-temporal deep learning approach [J]. *Transportation Research Part C: Emerging Technologies*, 2017, 85: 591-608.
- [10] Heilig M, Mallig N, Schröder O, et al. Implementation of free-floating and station-based carsharing in an agent-based travel demand model [J]. *Travel Behaviour and Society*, 2018, 12: 151-158.
- [11] Wang N, Guo J, Liu X, et al. A service demand forecasting model for one-way electric car-sharing systems combining long short-term memory networks with granger causality test [J]. *Journal of Cleaner Production*, 2020, 244: 118812.
- [12] Correia G H D A, Antunes A P. Optimization approach to depot location and trip selection in one-way carsharing systems [J]. *Transportation Research Part E: Logistics and Transportation Review*, 2011, 48(1): 233-247.
- [13] Correia G H D A, Jorge D R, Antunes D M. The added value of accounting for users' flexibility and information on the potential of a station-based one-way car-sharing system: an application in lisbon, portugal [J]. *Journal of Intelligent Transportation Systems*, 2014, 18(3): 299-308.
- [14] Smith S L, Pavone M, Schwager M, et al. Rebalancing the rebalancers: Optimally routing vehicles and drivers in mobility-on-demand systems [C]//*Proceedings of the 2013 American Control Conference*. New York: IEEE, 2013.
- [15] He L, Mak H Y, Rong Y, et al. Service region design for urban electric vehicle sharing systems [J]. *Manufacturing & Service Operations Management*, 2017, 19(2): 309-327.
- [16] Kek A G H, Cheu R L, Chor M L. Relocation simulation model for multiple-station shared-use vehicle systems [J]. *Transportation Research Record*, 2006, 1986, 1: 81-88.
- [17] Alfian G, Rhee J, Yoon B. A simulation tool for prioritizing product-service system (PSS) models in a carsharing service [J]. *Computers & Industrial Engineering*, 2014, 70: 59-73.
- [18] Illgen S, Höck M. Electric vehicles in car sharing networks-challenges and simulation model analysis [J]. *Transportation Research Part D: Transport and Environment*, 2018, 63: 377-387.
- [19] Lin K, Zhao R, Xu Z, et al. Efficient large-scale fleet management via multi-agent deep reinforcement learning [M]. New York, NY: ACM, 2018: 1774-1783.
- [20] Zhang D, Liu Y, He S. Vehicle assignment and relays for one-way electric car-sharing systems [J]. *Transportation Research Part B: Methodological*, 2019, 120: 125-146.
- [21] Balac M, Ciari F. Enhancement of the carsharing fleet utilization [C]//*Proceedings of the 15th Swiss Transport Research Conference*, 2015.
- [22] Jorge D, Barnhart C, De Almeida Correia G H. Assessing the viability of enabling a round-trip carsharing system to accept one-way trips: application to logan airport in Boston [J]. *Transportation Research Part C: Emerging Technologies*, 2015, 56: 359-372.
- [23] Shaw P. Using Constraint programming and local search methods to solve vehicle routing problems [C]//*Proceedings of the Principles and Practice of Constraint Programming*, Berlin, German: Springer, 1998: 417 - 431.
- [24] Gu W, Cattaruzza D, Ogier M, et al. Adaptive large neighborhood search for the commodity constrained split delivery VRP [J]. *Computers & Operations Research*, 2019, 112: 104761.
- [25] Roozbeh I, Ozlen M, Heame J W. An Adaptive Large Neighbourhood Search for asset protection during escaped wildfires [J]. *Computers & Operations Research*, 2018, 97: 125-134.
- [26] Demir E, Bektas T, Laporte G. An adaptive large neighborhood search heuristic for the Pollution-Routing Problem [J]. *European Journal of Operational Research*, 2012, 223(2): 346-359